같은 출발점에서 A2C와 PPO를 비교했습니다

A2C 사전 학습 가중치를 고정하고, 이후 업데이트 알고리즘을 나누어 추가 학습했습니다.

동일한 A2C 사전 학습 모델

정책망 · 가치망 가중치 복사 / 양쪽 모두 새 Adam 최적화기

A2C 추가 학습	30만 F
PPO 추가 학습	30만 F

환경·입력	같은 실시간 게임 / 관측 2,240개 / 5행동 / 18프레임 유지
공통 학습 설정	학습률 0.00005 · 엔트로피 0.005 · 환경 4개 · 환경당 128행동 수집
반복과 평가	학습 시드 3개 / 알고리즘·시드당 800판 / 마지막 모델을 주 비교
PPO 갱신	배치 128 · 최대 4회 반복 · clip 0.1 · target KL 0.02

비교 질문: "같은 사전 학습 정책을 어느 방식으로 추가 학습할 때 성능이 유지되는가?"

집계: 선택한 8개 스테이지 · 확률적 100판씩 · 추가 학습 시드 11 / 22 / 33

시드에 따라 성능 차이가 달라졌습니다

같은 추가 예산까지 학습한 last_model 기준 · 각 수치는 동일한 최종 평가 시드에서 측정했습니다.

학습 시드	귀환 성공률		별 3개 비율		평균 점수	
	A2C	PPO	A2C	PPO	A2C	PPO
11	98.63%	99.25%	97.63%	98.13%	94.17	94.82
22	98.00%	97.00%	97.38%	95.25%	93.64	92.41
33	98.50%	98.25%	97.75%	97.13%	94.03	93.83
평균 ± 표준편차	98.38 ± 0.33	98.17 ± 1.13	97.58 ± 0.19	96.83 ± 1.46	93.95 ± 0.28	93.69 ± 1.21

시드 11에서는 PPO가 높았고, 시드 22·33에서는 A2C가 높았습니다.

표준편차는 3개 학습 시드 간 값입니다. 비율의 표준편차 단위는 %p입니다.

알고리즘 평균과 시연 모델 선택을 구분했습니다

평균 성능의 해석과 특정 모델 한 개의 채택은 서로 다른 판단입니다.

3개 시드에서 관찰한 결과

별 3개 평균

A2C 97.58% **PPO 96.83%**

별 3개 비율의 시드 간 표준편차

A2C 0.19%p **PPO 1.46%p**

이번 조건에서는 A2C의 평균 수치가
조금 높고, 시드 간 변동은 작았습니다.
3개 시드의 관찰 결과로 보편적 우위를
확정하지 않습니다.

게임 시연용으로 선택한 모델

PPO · seed 11 · benchmark 후보

귀환 성공률 99.25%

별 3개 비율 98.13%

성능이 높았던 특정 시드의 모델을
보관했습니다.
개별 모델의 결과와 알고리즘의
평균 성능을 구분해 제시합니다.

발표 결론: 같은 사전 학습 정책의 추가 학습을 비교했고, 시드 변동까지 확인한 뒤 시연 모델을 선택했습니다.