게임 상태를 읽고, 행동을 배우는 PPO

실시간 탐사 환경에 관측 · 행동 선택 · 보상 피드백을 연결했습니다.

640 차원 관측

지형 · 아이템 · 유령 · 시간	630
실제 이동 가능 방향	4
목표 단계 · 방향 · 온기 조건	6

환경과 목표는 별도 신경망 분기로 처리합니다.
이동 정보는 행동 마스크에 사용합니다.



PPO 정책 재생 · Stage 2 · 결정적 플레이

게임 상태 수치 관측 → **PPO 정책** 행동 확률 → **이동 · 대기** 환경 변화 → **보상 · 경험** 정책 / 가치 갱신

실제 Stage 2 정책 재생 화면 · 이동 4방향과 대기
선택한 행동을 최대 9프레임 유지

별 3개를 향해, 부분 행동을 연결하다

성공 경험이 부족한 문제를 보상 설계와 단계별 복습으로 풀었습니다.

REWARD

무엇을 잘했다고 알려줄 것인가?

수집 · 목표 접근 · 별 획득
긍정적인 피드백

시간 낭비 · 벽막힘 · 피해
비용 부여

게임 점수와 학습 보상은 구분

CURRICULUM

쉬운 과제부터 전체 플레이로

물건 획득 → 자석과 연결
짧은 부분 과제부터 연습

기존 행동을 함께 복습
추가 수집 · 귀환으로 확장

중간 시작 상태와 실제 시작점 평가를 구분

PPO / ACTOR–CRITIC

경험으로 배우고 작게 갱신하기

정책망: 다음 행동 선택
가치망: 향후 보상 예측

Clipping으로 갱신 폭 제한
Stable-Baselines3 PPO 적용

목표 안내를 입력받고 행동은 정책이 선택

초반 온기 · 자석 → 물건 획득 → 추가 온기 → 출구 귀환

코드가 목표 순서와 경유지를 안내하고, 실제 이동·대기 행동은 PPO 정책이 선택합니다.

클리어는 안정적, 유령 회피는 남은 과제

실제 시작점의 확률적 플레이로 평가 · 실패한 판도 평균 별에 포함

평가 대상	성공	별 3개	평균 별
Stage 1 · 새 시드 100판	96%	95%	2.87
Stage 2 · 선택 평가 100판	96%	82%	2.63
Stage 2 · 최종 검증 200판	97.5%	74%	2.53

Stage 2 선택 모델은 약 45만 프레임 시점입니다.
최종 검증은 개선 후보가 없어 보존한 같은 모델의 결과입니다.

무피해 보완 실험의 판정: 목표 미달

약 15.4만 프레임에서 성능 보존 하한으로 중단
새 후보는 채택하지 않고 기존 모델을 보관했습니다.



결정적 화면 예시: 95점 · 별 3개 · 피해 1회
표의 통계는 확률적 플레이입니다.

최종 자석 활용 98%

평균 피해 1.155회 · 무피해 성공 6.5%