게임 상태를 읽고, 행동을 배우는 PPO

실시간 탐사 환경에 관측 · 행동 선택 · 보상 피드백을 연결했습니다.

640 차원 관측

지형 · 아이템 · 유령 · 시간	630
실제 이동 가능 방향	4
목표 단계 · 방향 · 온기 조건	6

환경과 목표는 별도 신경망 분기로 처리합니다.
이동 정보는 행동 마스크에 사용합니다.



PPO 정책 재생 · Stage 2 · 결정적 플레이

게임 상태 수치 관측 → **PPO 정책** 행동 확률 → **이동 · 대기** 환경 변화 → **보상 · 경험** 정책 / 가치 갱신

실제 Stage 2 정책 재생 화면 · 이동 4방향과 대기
선택한 행동을 최대 9프레임 유지

별 3개를 향해, 부분 행동을 연결하다

성공 경험이 부족한 문제를 보상 설계와 단계별 복습으로 풀었습니다.

REWARD

무엇을 잘했다고 알려줄 것인가?

수집 · 목표 접근 · 별 획득
긍정적인 피드백

시간 낭비 · 벽막힘 · 피해
비용 부여

게임 점수와 학습 보상은 구분

CURRICULUM

쉬운 과제부터 전체 플레이로

물건 획득 → 자석과 연결
짧은 부분 과제부터 연습

기존 행동을 함께 복습
추가 수집 · 귀환으로 확장

중간 시작 상태와 실제 시작점 평가를 구분

PPO / ACTOR–CRITIC

경험으로 배우고 작게 갱신하기

정책망: 다음 행동 선택
가치망: 향후 보상 예측

Clipping으로 갱신 폭 제한
Stable-Baselines3 PPO 적용

목표 안내를 입력받고 행동은 정책이 선택

초반 온기 · 자석 → 물건 획득 → 추가 온기 → 출구 귀환

코드가 목표 순서와 경유지를 안내하고, 실제 이동·대기 행동은 PPO 정책이 선택합니다.

클리어는 안정적, 유령 회피는 남은 과제

실제 시작점의 확률적 플레이로 평가 · 실패한 판도 평균 별에 포함

평가 대상	성공	별 3개	평균 별
Stage 1 · 새 시드 100판	96%	95%	2.87
Stage 2 · 선택 평가 100판	96%	82%	2.63
Stage 2 · 최종 검증 200판	97.5%	74%	2.53

Stage 2 선택 모델은 약 45만 프레임 시점입니다.
최종 검증은 개선 후보가 없어 보존한 같은 모델의 결과입니다.

무피해 보완 실험의 판정: 목표 미달

약 15.4만 프레임에서 성능 보존 하한으로 중단
새 후보는 채택하지 않고 기존 모델을 보관했습니다.



결정적 화면 예시: 95점 · 별 3개 · 피해 1회
표의 통계는 확률적 플레이입니다.

최종 자석 활용 98%

평균 피해 1.155회 · 무피해 성공 6.5%

1장 설명 · 게임과 PPO의 연결

발표용 PDF는 3장입니다. 뒤의 설명 자료는 발표 준비를 위한 대본·상세 설명·근거입니다.

그대로 읽을 수 있는 발표 대본

"까망이가 온기와 물건을 모아 귀환하는 행동을 PPO 강화학습으로 학습시켰습니다. 게임 내부 상태를 640개 숫자로 전달하고, AI가 네 방향 이동과 대기 중 다음 행동을 선택합니다. 환경 정보와 목표 정보를 별도 신경망 분기로 처리해 현재 상황과 가야 할 방향을 구분하도록 했습니다. 이동할 수 없는 방향과 효과 없는 상호작용은 마스크로 제외합니다. 선택한 행동을 최대 9프레임 유지한 뒤 다음 상태를 관찰하고, 플레이 경험과 보상을 이용해 정책을 갱신합니다."

640개 관측에는 무엇이 들어 있나?

구성 | 수 | 정보

실시간 환경 | 630 | 벽·출구, 캐릭터 위치·용기·보호·온기, 시간, 아이템, 유령 경로·상태·실제 위치, 물건·자석 상태 등

이동 가능 여부 | 4 | 실제 몸체 충돌과 닫힌 문을 반영한 네 방향 이동 가능 정보

목표 정보 | 6 | 물건·수집·귀환 단계 3개, 목표 상대 방향 2개, 기본 온기 조건 충족 여부 1개

신경망과 행동 마스크

환경 630개는 32개 특징으로, 목표 6개도 32개 특징으로 변환합니다. 합친 64개 특징에서 정책망과 가치망으로 이어집니다. 각 망은 64개 노드의 은닉층 두 개를 사용합니다. 이동 정보 4개는 특징 분기에 섞지 않고 행동 마스크에 사용합니다.

행동 공간의 원래 슬롯은 6개지만, 현재 PPO 정책은 효과 없는 상호작용을 제외합니다. 발표에서는 "네 방향 이동과 대기"라고 설명하는 것이 정확합니다. 유령 위험 방향을 자동 차단하는 마스크는 사용하지 않습니다.

프레임과 학습량을 설명할 때

1틱은 18물리 프레임이고 행동 반복은 최대 9프레임입니다. 100만 물리 프레임은 약 11만 번의 행동 선택에 해당하며, 종료 프레임에 따라 달라집니다. 물리 프레임, 행동 선택 수, 게임 판수는 서로 다른 단위입니다.

구현 근거: kkamang/env.py · rl/ppo_observation.py · rl/ppo_features.py · rl/ppo_policy.py · rl/ppo_action_repeat.py

2장 설명 · 어떻게 배우게 했나?

발표 대본

"처음부터 전체 게임을 반복하는 방식만으로는 성공 경험이 부족했습니다. 그래서 물건 획득처럼 짧은 과제를 먼저 연습하고, 초반 온기와 자석 수집을 함께 연결했습니다. 한 행동을 새로 익히면서 기존 행동을 잊지 않도록 복습 구간도 섞었습니다. 온기와 물건 획득, 목표 접근, 높은 점수와 별에는 보상을 주고, 시간 낭비와 벽막힘, 유령 피해에는 비용을 줍니다. PPO는 정책망과 가치망을 함께 학습하며, clipping으로 정책 갱신 폭을 제한합니다."

PPO를 선택한 이유와 실제 구현

우리 게임은 다음 행동을 확률로 선택하는 이산 행동 문제입니다. Stable-Baselines3의 PPO를 기반으로 게임용 특징 추출기와 행동 마스크를 연결했습니다. Actor는 행동 확률을 계산하고 Critic은 상태의 향후 보상을 추정합니다. 수집한 경험을 미니배치로 나누어 반복 학습합니다.

Clipping은 새 정책과 이전 정책의 행동 확률 비율을 제한하는 목적함수 구성입니다. "성공을 보장한다" 또는 "절대 성능이 떨어지지 않는다"는 의미는 아닙니다. 다른 알고리즘보다 우수하다는 비교 실험을 수행한 것으로 발표하지 않습니다.

보상과 게임 점수의 차이

게임의 별은 온기·속도·남은 용기 점수를 합쳐 85점 이상일 때 3개입니다. 학습 보상은 그 목표를 배우도록 만든 별도의 피드백입니다. 기본 클리어 온기는 4점이며, 학습 안내는 추가 수집을 위해 14점을 목표로 합니다. 시간·용기 여유가 부족하면 기본 조건 확보와 귀환을 우선하도록 안내합니다.

학습 피드백 | 역할

온기·물건·자석 획득 | 필수 수집 행동과 아이템 활용을 장려

목표 거리 감소 / 증가 | 올바른 방향에 빠른 피드백. 경유지·벽을 고려해 계산

최종 성공·점수·별 | 전체 과제와 고득점 귀환을 연결

시간·벽막힘·정체·피해 비용 | 무의미한 행동과 위험한 이동을 줄이는 신호

커리큘럼과 자석 안내

쉬운 중간 상태에서 시작하는 복습과 실제 시작점 플레이를 혼합합니다. 중간 상태는 실제 게임 이동으로 준비하며 그동안 경과한 게임 시간·획득 상태를 유지합니다. 자석은 1점 온기를 주변 3×3 범위에서 흡수하고, 3점 온기는 직접 밟아야 합니다. 목표 안내에도 이 규칙과 남은 효과 시간을 반영했습니다.

PPO 근거: Schulman et al., 2017 · Stable-Baselines3 공식 PPO 문서
구현: rl/train_ppo.py · rl/ppo_curriculum.py · rl/ppo_goal.py · rl/ppo_reward.py

3장 설명 · 성과를 어떻게 해석하나?

발표 대본

"평가는 준비된 중간 상태가 아닌 실제 시작점에서 진행했습니다. Stage 1 보관 모델은 새 시드 100판에서 성공률 96%, 별 3개 획득률 95%였습니다. Stage 2는 선택 평가에서 성공률 96%, 별 3개 82%였고, 최종 새 시드 200판에서 성공률 97.5%, 별 3개 74%였습니다. 자석 활용은 98%였지만 평균 피해는 1.155회로 유령 회피가 남은 과제입니다. 무피해 보완 실험은 성능 보존 하한 미달로 중단됐고, 개선된 후보 대신 기존 모델을 보관했습니다."

표에 사용한 실제 평가 수치

평가 | 성공 | 별 3개 | 평균 별

Stage 1 · 새 시드 | 96% | 95% | 2.87

Stage 2 · 선택 평가 | 96% | 82% | 2.63

Stage 2 · 최종 검증 200판 | 97.5% | 74% | 2.53

모두 실제 시작점 평가입니다. Stage 1과 Stage 2 선택 평가는 확률적 100판, 최종 검증은 확률적 200판입니다. Stage 1은 보관한 새 시드 평가, Stage 2 선택 평가는 최적 모델을 고르는 데 사용한 평가입니다. 최종 검증은 보존한 기존 모델을 60,000~60,199번 새 시드로 확인한 결과입니다. 새 맵에 대한 일반화 성능을 뜻하지 않습니다.

결정적 플레이와 확률적 플레이

결정적 플레이는 확률이 가장 높은 행동을 선택합니다. 확률적 플레이는 정책이 출력한 분포에서 행동을 뽑습니다. 최종 사용 방식에 맞춰 확률적 평가를 주 기준으로 사용했고, 결정적 플레이와 유령 초기 위상별 평가는 보조 지표로 기록했습니다.

Stage 2 결정적 화면 예시는 95점·별 3개·피해 1회입니다. 그 한 장면의 성공을 확률적 성공률 100%로 표현하면 안 됩니다. 같은 고정 환경에서 다른 시드의 결정적 재생이 같은 경로를 반복할 수도 있습니다.

이미 확인한 성과와 현재 목표

확인한 성과는 자석·물건·추가 수집·귀환의 연결입니다. 무피해 플레이의 안정성은 남은 과제입니다. 무피해 보완 실험의 목표는 성공 90%, 별 3개 90%, 평균 별 2.7개 이상과 평균 피해 0.1회 이하를 목표로 합니다. 학습은 약 154,308프레임에서 중단됐고 최종 200판 검증도 목표를 통과하지 못했습니다.

최종 보고서에서 final_stage2_passed는 false입니다. 추가 보완의 성공으로 발표하지 않고 현재 성과와 한계를 함께 설명합니다.

예상 질문과 기술 근거

Q. 경로를 전부 하드코딩한 것 아닌가요?
A. 목표 순서와 최단 경로의 경유지는 코드가 안내합니다. 준비 경로는 커리큘럼 시작 상태를 만드는 데 사용합니다. 실제 이동·대기 행동과 행동 확률은 PPO 정책이 선택합니다. 따라서 목표 안내를 포함한 강화학습 구조라고 설명합니다.

Q. 게임 화면을 보고 학습하나요?
A. 현재 모델은 픽셀 이미지 대신 게임 내부 상태를 숫자로 입력받습니다. 학습된 정책의 행동을 기존 게임 렌더러로 재생합니다.

Q. 자석을 배웠다는 근거는 무엇인가요?
A. 자석을 먹었는지와 실제 원격 수집에 사용했는지를 구분했습니다. Stage 2 최종 새 시드 200판의 실제 활용률은 98%입니다.

Q. Stage 1과 Stage 2 모델을 합쳤나요?
A. 기존 가중치를 다음 학습의 출발점으로 가져와 미세 조정했습니다. 여러 ZIP의 행동을 합산하는 방식은 아닙니다. 현재 실험은 새 최적화기로 이어 학습합니다.

Q. 병렬 환경 4개면 CPU 코어도 4개인가요?
A. 현재는 DummyVecEnv 4개와 Torch 스레드 1개 설정입니다. 환경 4개에서 경험을 모은다는 뜻이며, 4개 프로세스로 동시에 실행한다는 뜻은 아닙니다.

성과 모델과 마무리 설정을 혼동하지 않기

항목 | 표의 Stage 2 모델 | 무피해 보완 실험 설정

학습률 / PPO clip | 0.00005 / 0.2 | 0.00002 / 0.1

반복 / 엔트로피 | 10회 / 0.01 | 10회 / 0.003

학습 예산 | 약 50만 물리 프레임 | 추가 최대 약 100만 물리 프레임

피해 / 무피해 보상 | -1 / 완료 시 +2 | -6 / 무피해 별 3개 완료 시 +8

프로젝트 내 근거 파일

① Stage 1: reports/local/stage1/evaluation/heldout_seeds/evaluation.json
② Stage 2 선택: stage2_magnet_connection_full/quick/
seed_11_20261101_032919_437907/evaluation/step_451765/evaluation.json
②의 경로 앞에는 reports/local/experiments/를 붙입니다.
③ Stage 2 새 시드: 이 산출물 폴더의 stage2_new_seeds_evidence.json
④ 현재 설정: rl/ppo_config.py · 최종 절차: rl/PPO_STAGE2_SAFE_RETURN_FINAL.md
최종 검증 200판: 이 산출물 폴더의 final_stage2_evidence.json

공식 문헌

Proximal Policy Optimization Algorithms — Schulman et al. (2017)
Stable-Baselines3: PPO 공식 문서

제작 기준일: 2026-11-01 (Asia/Seoul). 최종 보완 실험 결과까지 반영했습니다. Canva 편집 화면에 접근할 수 없어, 실제 게임 화면과 코드·평가 기록으로 독립 구성했습니다. 학습과 게임 소스 편집은 수행하지 않았습니다.

최종 보완 실험 · 결과와 해석

실행: seed_11_20261101_040335_220183 / 종료: performance_retention_stopped

같은 선택 평가 시드에서 비교

시점 | 클리어 | 별 3개 | 평균 별 | 평균 피해

출발 모델 | 96% | 82% | 2.63 | 1.16

54,372F | 98% | 74% | 2.45 | 1.21

104,398F | 97% | 65% | 2.30 | 1.27

154,308F | 98% | 73% | 2.49 | 1.17

별 3개 80%·평균 별 2.5개 하한을 세 번 연속 충족하지 못해 중단했습니다. 클리어 성공률은 높았지만 별 획득이 줄었고 피해도 개선되지 않았습니다.

최종 200판의 의미

선택 시점은 0프레임이며, 보존한 best_model의 신경망 가중치는 이전 모델과 동일함을 확인했습니다. 따라서 성공 97.5%·별 3개 74%·평균 별 2.525개·평균 피해 1.155회는 새로 개선된 정책의 결과가 아닙니다.

이전 선택 평가 100판의 별 3개 82%와 최종 새 시드 200판의 74%는 서로 다른 평가 표본입니다. 같은 모델의 수치를 비교해 정책이 퇴보했다고 결론 내리지 않습니다. 추가 학습 후보의 하락은 위의 같은 시드 비교로 판단합니다.

원인에 대해 말할 수 있는 범위

반복적으로 피해 1회를 받는 기존 행동을 보상 강화와 위상 복습만으로 안전한 행동으로 바꾸지 못했습니다. 정확히 어떤 요소가 원인인지 분리한 대조 실험은 수행하지 않았으므로 특정 보상 계수 하나를 확정 원인으로 주장하지 않습니다.

프로젝트를 여기서 정리할 때

검증된 기존 모델을 채택하고 현재 성공률·별 획득률·피해량을 그대로 발표합니다. 성능 보존 장치가 열화된 후보를 채택하지 않았다는 점과 유령 회피가 남은 과제라는 점을 함께 제시합니다.

근거: reports/local/experiments/stage2_safe_return_final/quick/seed_11_20261101_040335_220183/training_summary.json 및 final_verification/evaluation.json